GUION ORAL / DIAPOSITIVAS 1-4

Detección de fraude en reclamos de seguros

8:45 minutos de exposición · Tiempos orientativos

1. Qué reclamos conviene revisar primero 0:35

Predecimos si un reclamo queda marcado como fraude reportado. El puntaje sirve para ordenar expedientes y asignar tiempo de revisión. La decisión final la toma quien investiga el caso.

2. Datos y diseño de la prueba 1:00

Los cuatro modelos se evaluaron en los mismos 200 reclamos, con 49 positivos. Los ajustes se hicieron con entrenamiento. Quitamos identificadores y el importe total redundante. Suponemos que la severidad y los importes ya están registrados al priorizar. La disponibilidad de aficiones debe verificarse.

3. Qué aportan KNN y la logística 1:05

KNN estandariza y busca casos parecidos. Con muchas variables codificadas, la distancia parece poco informativa en esta muestra y la ROC queda cerca de la diagonal. La logística con pesos de clase es una referencia rápida y más interpretable. Detecta más fraudes en el umbral usado.

4. Random Forest: capacidad de ordenar 1:00

El bosque combina 150 árboles. La validación eligió una profundidad máxima de 8. La diferencia entre entrenamiento y prueba muestra sobreajuste, aunque la validación anticipó bien el resultado de prueba. La AUC indica qué tan bien ordena casos positivos por encima de negativos.

GUION ORAL / DIAPOSITIVAS 5-8

Resultados y conclusión

8:45 minutos de exposición · Tiempos orientativos

5. Random Forest: qué cambia con el umbral 1:05

Con un umbral de 0,50, el modelo detecta 4 de los 49 fraudes reportados. Con el umbral de 0,309, elegido al maximizar F1 en validación, detecta 42 de 49. Para conseguirlo, marcaría 66 de los 200 reclamos, incluidos 24 falsos positivos. La AUC es la misma porque el orden de los puntajes no cambia. El umbral operativo dependería de cuántos reclamos se puedan revisar y del costo de cada tipo de error.

6. Qué aprendió XGBoost 1:25

XGBoost construye árboles de forma secuencial. Cada árbol busca reducir los errores que quedan en el conjunto. Probamos 200 configuraciones en validación cruzada y elegimos la de mayor AUC. Después fijamos el umbral de 0,26 maximizando F1 con predicciones de validación. En prueba, el modelo obtuvo una AUC de 0,823 y un F1 de 0,730. La severidad y las aficiones concentraron cerca del 60 % de la ganancia de los árboles. Esa concentración nos llevó a probar una regresión logística con solo esas dos variables.

7. Comparación final 1:15

Random Forest obtuvo la mayor AUC de prueba, 0,857. A los umbrales elegidos, el bosque y XGBoost marcaron los mismos 66 reclamos y detectaron 42 de los 49 positivos. La logística exploratoria con severidad y aficiones también marcó esos mismos casos y logró una AUC de 0,844. Eso muestra que los puntajes pueden ordenar distinto y llevar a la misma decisión de revisión. En la tabla, la logística de referencia usa todos los predictores y obtiene 0,781. KNN queda cerca del azar.

8. Recomendación y límites 1:20

Para ordenar reclamos en esta muestra, recomendamos Random Forest. La recomendación depende de que la señal se mantenga en otros datos. Si retiramos severidad y aficiones, la AUC de validación del bosque cae de 0,857 a 0,600. Antes de usarlo, verificaríamos de dónde salen esas variables y haríamos una evaluación temporal.