PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

Aplicaciones en Finanzas con Machine Learning | Segundo semestre 2026

Tarea 2

Detección Automatizada de Fraude en Reclamos de Seguros de Automóvil mediante Aprendizaje Automático

Integrantes:

- Fernán Gazmuri
- Vicente Riffo
- Albert Roca

Profesor: Joaquín Aguirre

Introducción

El problema financiero que abordaremos en este informe es la "detección de fraude en seguros de autos", utilizando como base de datos la *Insurance Claims Dataset* disponible gratuitamente en la plataforma online Kaggle, que cuenta con entre 1.000 a 100.000 registros de siniestros tabulares con variables demográficas, del vehículo y del incidente.

Nuestra variable objetivo de tipo binaria será *fraud_reported* (1 = reclamo fraudulento, 0 = reclamo legítimo). La predicción de esta variable es de vital importancia en la industria aseguradora, ya que la asimetría de información y el riesgo moral representan fallas de mercado estructurales con un costo económico directo para las instituciones financieras.

El impacto financiero del fraude en seguros no se limita únicamente a la pérdida inmediata de capital al indemnizar un siniestro falso o inflado. Sus consecuencias se ramifican en tres niveles financieros clave: el deterioro el margen técnico y ratio combinado, el sobrecosto estructural para la sociedad (efecto contagio en primas) y los costos de oportunidad asociados (costos administrativos insostenibles y retrasos en el pago de indemnizaciones legítimas).

Este pronóstico es utilizado principalmente por la Unidad de Investigaciones Especiales (SIU, por sus siglas en inglés) y el Departamento de Siniestros (*Claims Department*) de las compañías aseguradoras. Su objetivo es auditar preventivamente los reclamos de alto riesgo antes de autorizar el pago de indemnizaciones.

Preparación de los datos

Previo a la realización de los modelos, la base de datos se sometió a un riguroso preprocesamiento de preparación, de modo de garantizar el rigor metodológico, prevenir la fuga de información y cumplir con los requerimientos técnicos de los modelos a comparar. El conjunto de datos original contiene 1.000 observaciones y 40 variables con información socioeconómica del asegurado, detalles de la póliza y características del siniestro. Se ejecutó un flujo sistemático de depuración y preparación estructurado en los siguientes cinco pasos:

1. **Depuración de Identificadores y Reducción de Ruido:** Se eliminó la columna residual "_c39" por presentar un 100% de valores nulos. Asimismo, se descartaron los identificadores unívocos y de alta cardinalidad (policy_number, insured_zip e incident_location). Conservar códigos postales específicos o números de póliza induce a que los modelos basados en árboles (Random Forest y XGBoost) memoricen casos individuales en lugar de aprender patrones de riesgo generalizables, provocando sobreajuste (*overfitting*).

2. **Ingeniería de Características y Control de Fuga de Información:** Para garantizar el uso exclusivo de información disponible al momento del reporte del siniestro, las variables de fecha original *(policy_bind_date* e *incident_date*) se transformaron en variables numéricas relativas. La primera "*días_desde_emision*" (Diferencia en días

entre la fecha del accidente y la fecha de emisión de la póliza) y otros componentes estacionales (*incident_month* e *incident_day_of_week)*, indicadores numéricos para capturar variaciones según el mes del año y la dinámica entre días hábiles y fines de semana. Posteriormente, las columnas de fecha originales fueron removidas.

3. **Imputación y Tratamiento de Valores Faltantes:** Las variables *collision_type, property_damage* y *police_report_available* registraban valores nulos codificados bajo el símbolo "?". Dado que en el ámbito asegurador la omisión del tipo de colisión o la ausencia de un informe policial constituye una señal con valor predictivo de riesgo, los valores faltantes no fueron eliminados ni imputados por la moda; en su lugar, se convirtieron explícitamente en una nueva categoría denominada 'MISSING'.

4. **Control de Multicolinealidad Perfecta:** La variable *total_claim_amount* corresponde a la suma aritmética exacta de tres subclases de reclamo: *injury_claim* (daños corporales), *property_claim* (daños a la propiedad) y *vehicle_claim* (daños del vehículo). Mantener el monto total junto con las tres componentes individuales genera una colinealidad perfecta que desestabiliza los coeficientes de la Regresión Logística. Por ello, se conservaron las tres subclases para mantener la granularidad del análisis y se eliminó la columna *total_claim_amount.*

5. **Codificación del Target y Preparación Estructural:** La variable objetivo *fraud_reported* se codificó binariamente asignando el valor "1" a las solicitudes fraudulentas (Y) y "0" a las legítimas (N), registrando una prevalencia base del 24,7% de casos positivos frente a un 75,3% de casos negativos. El dataset final consta de 36 variables depuradas, listas para la codificación categórica (One-Hot Encoding), la partición estratificada en muestras de entrenamiento/prueba (80/20) y la estandarización de escala (StandardScaler) exigida por el algoritmo KNN.

<u>Modelo KNN</u>

El desempeño de KNN depende directamente de la geometría del espacio de características. Por ello, se aplicaron las dos transformaciones preliminares mencionadas en la sección anterior sobre el conjunto de datos depurado:

- Codificación categórica: Se convirtieron los atributos cualitativos (como *policy_state, incident_type* o *auto_make*) en variables binarias 0/1, permitiendo su inclusión en el cálculo de distancias.
- Estandarización de variables: Se aplicó una transformación ajustando la media y desviación estándar únicamente sobre la muestra de entrenamiento para evitar la fuga de información

Posteriormente, para encontrar la configuración óptima del modelo sin contaminar el conjunto de prueba, se implementó una búsqueda en malla con validación cruzada de 5 pliegues (5-Fold Cross Validation) sobre la muestra de entrenamiento estandarizada. Dado el desbalance de clases de la variable objetivo (24,7% de siniestros fraudulentos), se seleccionó la métrica F1-Score como función de scoring para guiar la búsqueda en malla, priorizando un equilibrio armónico entre la Precisión y el Recall en la detección de fraudes.

Desempeño Modelo KNN

	Set	AUC	Precisión	Recall	F1-Score
0	Entrenamiento	0.8651	0.7462	0.4899	0.5915
1	Prueba	0.4898	0.2581	0.1633	0.2000

Dado los resultados anteriores, las principales conclusiones son las siguientes:

- Hay una brecha de sobreajuste crítica. En entrenamiento, el modelo alcanza un AUC de 0.8651 y un F1-Score de 0.5915, en cambio, en el set de prueba, el AUC cae a 0.4898 (brecha de 0.3753) y el F1-Score cae a 0.2000 (brecha de 0.3915).
- El Recall en prueba es de solo 0.1633 (16.33%). El modelo deja pasar el 83.67% de los reclamos fraudulentos reales (Falsos Negativos), lo que se traduciría en pérdidas masivas por pago de siniestros no detectados para la aseguradora.
- La Precisión en prueba es de 0.2581, prácticamente igual a la prevalencia base del fraude en el dataset (~24.7%), lo que confirma que las predicciones positivas no agregan valor predictivo.
- Tras aplicar "*One-Hot Encoding"* a las variables categóricas, el espacio de características aumentó significativamente en dimensiones. En espacios multidimensionales, las distancias euclidianas se vuelven uniformes y pierden su capacidad de separar casos similares de disímiles. A este fenómeno se le conoce como la "maldición de la dimensionalidad".

Modelo XGBoost

Desempeño Modelo XGBoost

Set	AUC	Precisión	Recall	F1-Score
Entrenamiento	0.9443	0.6531	0.8939	0.7548
Prueba	0.8304	0.6364	0.8571	0.7304

A partir de los resultados anteriores, las principales conclusiones son las siguientes:

- Los hiperparámetros se eligieron sin usar la muestra de prueba. Se probaron 200 combinaciones al azar con validación cruzada de 5 particiones dentro del entrenamiento, maximizando el AUC. Ganó un modelo pequeño: 50 árboles de profundidad 3 y tasa de aprendizaje de 0.03, dando a cada fraude un peso de 3 para compensar que solo el 24.7% de los reclamos son fraude. El umbral de clasificación (0.24) también se eligió con validación cruzada.
- El desempeño fuera de muestra es bueno. En prueba, el modelo detecta el 85.71% de los reclamos fraudulentos (Recall) y el 63.64% de los reclamos que marca son efectivamente fraude, 2.6 veces la prevalencia base del fraude (24.5%).
- El sobreajuste es moderado. La brecha de AUC entre entrenamiento y prueba es de 0.1139, pero la del F1-Score es solo 0.0244. Al aumentar el número de árboles, la profundidad o la tasa de aprendizaje, el AUC de entrenamiento llega a 1.0 mientras el de validación cae desde 0.869 a cerca de 0.84, por lo que mantener el modelo simple fue clave.
- Dos variables explican casi todo. La gravedad del siniestro y el hobby del asegurado concentran el 93% de la ganancia de los árboles, y ninguna otra variable cambia el AUC de prueba en más de 0.004 al desordenarla. De hecho, el modelo se reduce a una regla: marcar como fraude si el daño es “Major Damage” o si el hobby es ajedrez o cross-fit. Esa regla reproduce el 100% de sus clasificaciones.
- Frente a la regresión logística, el XGBoost obtiene un AUC similar (0.830 vs 0.833) y un mejor F1-Score (0.730 vs 0.654). Sin embargo, una logística con solo las dos variables anteriores iguala sus clasificaciones con un AUC de 0.844 y menor sobreajuste. La flexibilidad del XGBoost no encontró interacciones adicionales en esta base; su principal aporte fue identificar qué variables importan.
- El costo computacional es bajo. Ajustar el modelo final toma 0.04 segundos; lo costoso es la búsqueda de hiperparámetros, que tomó 64 segundos (1.000 ajustes), contra 2.8 segundos para la regresión logística.

Regresión Logística

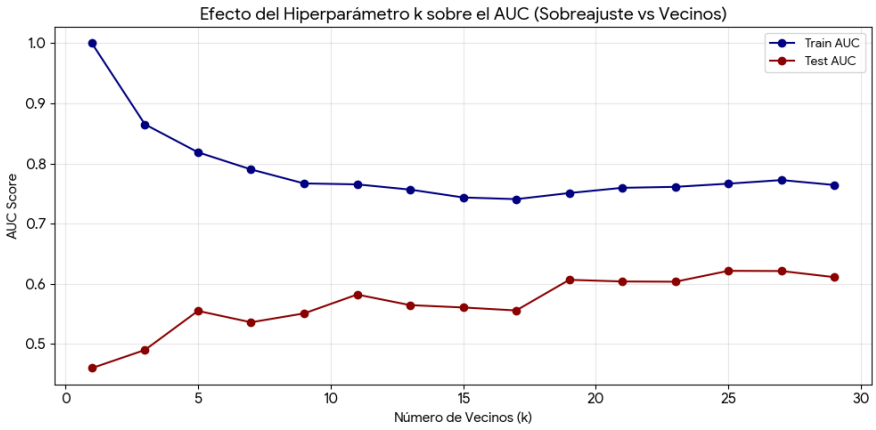
Además de los 3 modelos anteriores, se realizó una regresión logística sobre la base de datos para su posterior uso como punto de comparación.

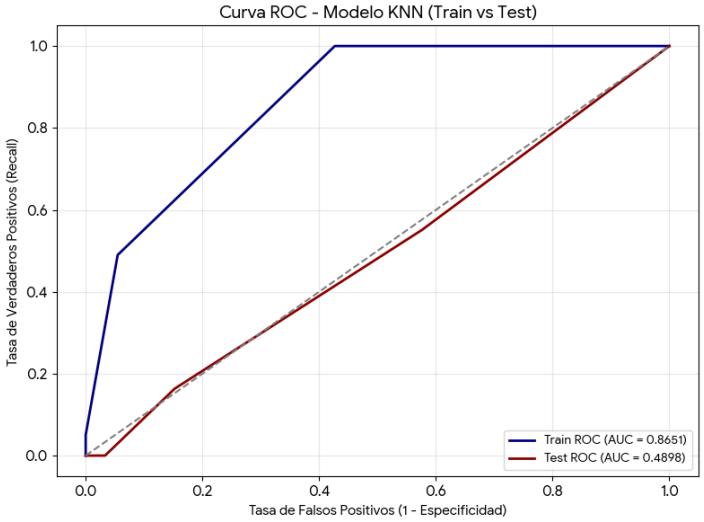
Dado que las clases muestran un desbalance inicial (24,7% reclamos fraudulentos vs. 75,3% legítimos), se configuró el hiperparámetro *class_weight='balanced'*. Esto ajusta automáticamente los pesos de la función de pérdida inversamente proporcionales a las frecuencias de clase en los datos de entrenamiento. Con esto se evita que el optimizador se sesgue a favorecer la clase mayoritaria y se penaliza fuertemente el error en la detección de fraudes (falsos negativos).

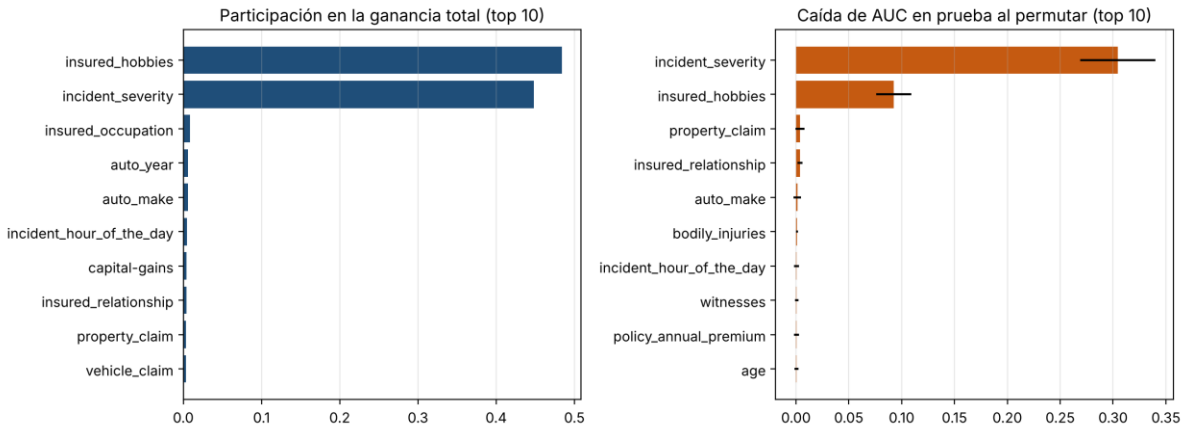
Resultados regresión logística

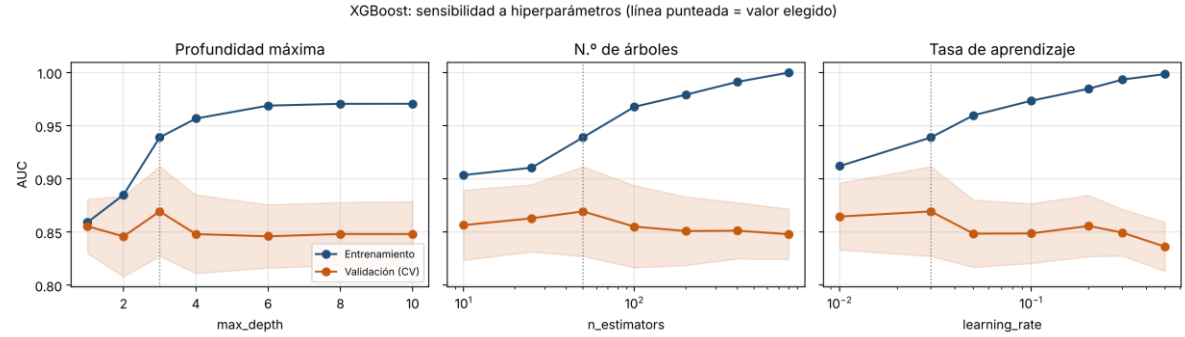
Set	AUC	Precision	Recall	F1-Score	Brecha AUC
Entrenamiento	0.9643	0.7410	0.9394	0.8285	-
Prueba	0.7800	0.5439	0.6327	0.5849	0.1843

Anexos


Efecto del Hiperparámetro k sobre el AUC (Sobreajuste vs Vecinos)
Train AUC
Test AUC
AUC Score
Número de Vecinos (k)
1.0
0.9
0.8
0.7
0.6
0.5
0
5
10
15
20
25
30


Curva ROC - Modelo KNN (Train vs Test)
Train ROC (AUC = 0.8651)
Test ROC (AUC = 0.4898)
Tasa de Verdaderos Positivos (Recall)
Tasa de Falsos Positivos (1 - Especificidad)
1.0
0.8
0.6
0.4
0.2
0.0
0.0
0.2
0.4
0.6
0.8
1.0


Participación en la ganancia total (top 10)
insured_hobbies
incident_severity
insured_occupation
auto_year
auto_make
incident_hour_of_the_day
capital-gains
insured_relationship
property_claim
vehicle_claim
0.0
0.1
0.2
0.3
0.4
0.5
Caída de AUC en prueba al permutar (top 10)
incident_severity
insured_hobbies
property_claim
insured_relationship
auto_make
bodily_injuries
incident_hour_of_the_day
witnesses
policy_annual_premium
age
0.00
0.05
0.10
0.15
0.20
0.25
0.30
0.35


XGBoost: sensibilidad a hiperparámetros (línea punteada = valor elegido)
Profundidad máxima
N.º de árboles
Tasa de aprendizaje
AUC
1.00
0.95
0.90
0.85
0.80
Entrenamiento
Validación (CV)
2
4
6
8
10
max_depth
10^1
10^2
n_estimators
10^{-2}
10^{-1}
learning_rate